

Proposta de Trabalho de Conclusão de Curso

Beatriz Viana Costa¹, Kelly Rosa Braghetto²

¹Departamento de Ciência da Computação – Instituto de Matemática e Estatística (IME/USP)
Rua do Matão, 1010 – São Paulo – SP – Brasil

beatrizvianacosta@usp.br¹, kellyrb@ime.usp.br²

Resumo. *A plataforma CulturaEduca.cc atua como um Sistema de Informações Geográficas participativo voltado à territorialização de políticas públicas e intersectorialidade entre equipamentos diversos. Entretanto, a extração de insights territoriais complexos na plataforma ainda é limitada pela rigidez de bancos de dados relacionais para consultas multicamada. Este trabalho propõe a migração de dados geoespaciais para uma arquitetura baseada em Bancos de Dados em Grafos integrada a Modelos de Linguagem de Grande Escala. A metodologia compreende a modelagem ontológica do território, a implementação de uma interface Text-to-Cypher via sistemas multi-agentes e a validação técnica por meio de métricas de acurácia de consultas e usabilidade com usuários finais.*

1. Introdução

1.1. Contextualização

A plataforma **CulturaEduca.cc** é um Sistema de Informações Geográficas (SIG) participativo e de software livre, cujo propósito central é a territorialização de políticas públicas. Baseada nas concepções de território de Milton Santos [Santos 2000] — que o define como o “território usado”, onde a técnica, a política e a vida cotidiana se encontram — a plataforma busca superar a fragmentação da gestão pública por meio da intersectorialidade. Ou seja, tem como objetivo promover a aprendizagem e a participação social, combinando conhecimento espacial, técnico e social.

Originalmente criada a partir de um convênio de 2011 entre o Instituto Lidas e os Ministérios da Cultura e da Educação (SICONV Nº 763256/2011), a ferramenta evoluiu de um mapeamento de escolas para uma plataforma de análise intraurbana complexa. Ela integra bases de dados oficiais (Censo/IBGE, INEP, CNES) com o mapeamento colaborativo de agentes locais, permitindo visualizar a relação entre equipamentos públicos e as condições socioeconômicas do entorno. Com quase 1,5 milhão de acessos em 2024, a plataforma demonstra ser um recurso vital para a saúde coletiva e a gestão educacional, embora ainda enfrente desafios na democratização do acesso a consultas complexas por usuários não especialistas.

1.2. Problema de Pesquisa

Embora o CulturaEduca ofereça uma vasta camada de dados, a recuperação de informações que cruzam diferentes setores (ex: relação entre a localização de escolas e a cobertura de unidades de saúde em áreas de alta vulnerabilidade) ainda depende de interfaces de mapa tradicionais ou consultas SQL complexas. Essa barreira técnica dificulta que gestores e comunidades extraiam *insights* imediatos sobre o território.

Além disso, a estrutura de dados relacional convencional limita a representação fluida de redes de proximidade e as relações de interdependência entre os serviços públicos, que são inerentemente conectadas de forma não linear.

1.3. Objetivo Geral

O objetivo central deste trabalho é potencializar a análise intersetorial da plataforma CulturaEduca por meio da modernização de sua infraestrutura de dados e interface de consulta, transformando bases brutas em conhecimento acessível para o planejamento ascendente de políticas públicas.

1.4. Objetivos Específicos

- Modernizar a estrutura de dados territorial por meio da transposição da lógica relacional para uma rede de grafos que reflita as conexões orgânicas do território.
- Investigar e implementar metodologias de análise multicamadas, permitindo a correlação espacial e semântica entre dados de educação, saúde e indicadores socioeconômicos.
- Democratizar o acesso à informação socioespacial eliminando barreiras técnicas de consulta para usuários não especialistas por meio de linguagem natural.
- Otimizar a análise intersetorial para a identificação de vazios assistenciais e o fortalecimento do planejamento ascendente de políticas públicas.
- Validar a viabilidade tecnológica da integração entre bancos de dados em grafos e LLMs como ferramenta de suporte à participação e ao controle social.

2. Conceitos

Esta seção apresenta os conceitos introdutórios e as terminologias necessárias para a compreensão integral das discussões apresentadas neste trabalho. A compreensão de modelos de armazenamento, linguagens de consulta e tecnologias de inteligência artificial é essencial para fundamentar a proposta de integração tecnológica descrita nas seções seguintes.

- **Banco de Dados Relacional:** Modelo de armazenamento de dados baseado em tabelas interconectadas por chaves.
- **Banco de Dados em Grafos:** Modelo focado no armazenamento de entidades (nós) e suas conexões (arestas).
- **Cypher:** Linguagem de consulta declarativa otimizada para bancos de dados em grafos.
- **LLM (*Large Language Model*):** Modelos de inteligência artificial treinados em vastos conjuntos de dados para compreender e gerar linguagem natural ou traduzir instruções para linguagens de programação.
- **Sistemas Multi-agentes:** Arquitetura de IA em que diferentes agentes especializados colaboram para decompor e resolver tarefas complexas.
- **ETL (*Extract, Transform, Load*):** Processo de integração que consiste em extrair informações de uma fonte, transformá-las para um novo formato e carregá-las no sistema de destino.

3. Trabalhos Relacionados

Esta seção apresenta os estudos que fundamentam a transição de dados geográficos para grafos e o uso de inteligência artificial para consultas complexas.

Diversos trabalhos tratam das vantagens de tecnologias NoSQL para geodados, como [Guo and Onstein 2020] e [Πετρίδης 2022], que demonstram como o Neo4j supera as limitações de esquemas relacionais na representação de redes e topologias espaciais. Essas referências justificam a escolha tecnológica para a infraestrutura de dados da plataforma CulturaEduca.

Para a etapa de modelagem, as fontes mais relevantes são [Seufitelli 2016] e [Agoub et al. 2016], que propõem métodos de mapeamento de esquemas conceituais geográficos e o enriquecimento de geodados padronizados. Tais estudos servirão de base para a representação da hierarquia territorial e das conexões intersetoriais entre educação e saúde neste projeto. No que tange à interface, trabalhos recentes como os de [Tiwari et al. 2025] e [Sutiagin 2025] apresentam *frameworks* para a tradução automática de linguagem natural para Cypher (*Text-to-Cypher*), focando na verificação de correção das consultas geradas. Este TCC utilizará essas técnicas para preencher a lacuna de acesso a informações complexas por usuários leigos, adaptando-as ao contexto específico da gestão pública brasileira.

4. Metodologia

A metodologia proposta adota uma abordagem de pesquisa-ação, estruturada nas seguintes etapas técnicas detalhadas:

- **Modelagem Ontológica do Território:** Definição da estrutura do banco de dados em grafos para representar a hierarquia territorial (setores censitários, distritos e municípios) e os equipamentos públicos. O modelo deve permitir a integração das diferentes camadas (educação, saúde e censo) por meio de vínculos de proximidade e localização.
- **Pipeline de ETL e Integração de Dados:** Implementação de procedimentos para extração e tratamento dos dados do banco de produção, realizando a carga dos registros para o ambiente de grafos, com foco inicial em São Paulo e São Bernardo do Campo.
- **Desenvolvimento da Interface de Consulta:** Exploração de técnicas de processamento de linguagem natural para permitir a tradução de perguntas dos usuários em consultas compatíveis com a base de dados em grafos.
- **Avaliação por Métricas de Qualidade:** Realização de testes para aferir a qualidade do mapeamento das consultas e a precisão das respostas geradas.

5. Resultados Esperados

Espera-se que a transposição da lógica de armazenamento e consulta para um modelo baseado em grafos potencialize a análise de fenômenos complexos no território, como a identificação de “vazios assistenciais” e a percepção de padrões de exclusão socioespacial de forma mais intuitiva. O produto final será um protótipo funcional capaz de interpretar perguntas em linguagem natural e realizar cruzamentos intersetoriais de dados. A título de exemplo, o sistema deverá ser capaz de processar consultas que relacionem diferentes dimensões das dinâmicas territoriais e dados censitários, tais como:

- Quais unidades de Ensino Fundamental estão localizadas em setores censitários com renda média mensal inferior a um salário mínimo?
- Quais escolas situadas em áreas de alta vulnerabilidade socioeconômica possuem projetos ou ações de agentes culturais cadastrados na plataforma?
- Quais equipamentos de saúde apresentam déficits de cobertura em territórios com alta densidade de população idosa (60 anos ou mais)?

A solução visa fornecer respostas diretas e fundamentadas em dados oficiais e colaborativos, potencializando o uso da plataforma CulturaEduca como uma ferramenta robusta de auxílio à tomada de decisão, ao planejamento intersetorial e ao fortalecimento do controle social.

6. Cronograma de Pesquisa

As atividades previstas para o desenvolvimento deste trabalho estão divididas em etapas que contemplam o desenvolvimento técnico, validações constantes com os colaboradores do projeto e a escrita contínua da monografia:

1. **Levantamento Bibliográfico:** Pesquisa aprofundada sobre ontologias geoespaciais e modelagem de dados no território intraurbano.
O foco recai sobre exemplos de modelagem de dados geoespaciais em grafos e a investigação de trabalhos existentes que abordam a tradução de linguagem natural para a linguagem de consulta Cypher.
2. **Preparação e Extração de Dados:** Acesso ao ambiente de produção da plataforma CulturaEduca para estudo e análise dos datasets de educação e saúde das regiões de São Paulo e São Bernardo do Campo.
Esta etapa baseia-se em trabalhos prévios realizados no âmbito do projeto para a seleção e extração de recortes específicos de dados. O objetivo é compreender a estrutura das bases existentes para definir os subconjuntos de dados necessários à modelagem das redes intersetoriais.
3. **Modelagem e Implementação do Grafo:** Definição das entidades (nós) e dos vínculos territoriais e intersetoriais no Neo4j.
Esta etapa envolve a implementação de rotinas ETL para a migração dos dados entre os dois modelos de banco de dados, relacional e em grafos, e a realização de experimentações com diferentes estruturas de grafos para melhor representar a hierarquia territorial.
4. **Validação da Estrutura e Mapeamento de Consultas:** Fase de testes da modelagem através do mapeamento manual de perguntas fundamentais (validadas previamente com colaboradores do CulturaEduca) e sua tradução direta para Cypher. O objetivo é verificar se a estrutura do banco suporta as análises intersetoriais e multicamadas desejadas antes da automatização.
5. **Desenvolvimento da Camada de Inteligência Artificial:** Configuração de agentes e elaboração de *prompts* em português para a tradução automática de linguagem natural em consultas Cypher.
6. **Análise e Discussão dos Resultados:** Realização de baterias de testes (*benchmarks*) para medir a acurácia da tradução automática e o tempo de resposta do sistema. Comparação qualitativa e quantitativa entre a abordagem em grafos e o modelo relacional tradicional.

7. **Escrita da Monografia:** Atividade transversal realizada durante todo o período da pesquisa. Consiste no registro da fundamentação teórica, das decisões de projeto, dos resultados parciais e das considerações finais do trabalho.

Atividade / Mês	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
1									
2									
3									
4									
5									
6									
7									

Tabela 1. Cronograma de atividades conforme os itens de planejamento.

Referências

- [Agoub et al. 2016] Agoub, A., Kunde, F., and Kada, M. (2016). Potential of graph databases in representing and enriching standardized geodata. *Tagungsband der*, 36:208–216.
- [Guo and Onstein 2020] Guo, D. and Onstein, E. (2020). State-of-the-art geospatial information processing in nosql databases. *ISPRS International Journal of Geo-Information*, 9(5).
- [Πετρίδης 2022] Πετρίδης, E. (2022). *Developing a web-based application for managing geospatial data with Neo4j*. PhD thesis, International Hellenic University.
- [Santos 2000] Santos, M. (2000). O papel ativo da geografia: um manifesto. *Revista Território*.
- [Seufitelli 2016] Seufitelli, D. B. (2016). Mapping geographic conceptual schemas to nosql graph databases. Master’s thesis, Universidade Federal de Minas Gerais.
- [Sutiagin 2025] Sutiagin, O. O. (2025). A multi-stage self-review framework for translating natural language into neo4j cypher queries. *Bionics of Intelligence ()*, 2(103):62–71.
- [Tiwari et al. 2025] Tiwari, A., Malay, S. K. R., Yadav, V., Hashemi, M., and Madhusudhan, S. T. (2025). Auto-cypher: Improving LLMs on cypher generation via LLM-supervised generation-verification framework. In Chiruzzo, L., Ritter, A., and Wang, L., editors, *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 2: Short Papers)*, pages 623–640, Albuquerque, New Mexico. Association for Computational Linguistics.